DOCUMENTO MAESTRO COMPLETO Y GUÍA DE PRESENTACIÓN OPERATIVA

NeuroLab Enterprise | Especificación Funcional, Técnica, Flujo Secuencial y Modelo Orientado a Datos

> 📌 **Resumen Ejecutivo del Documento Maestro Integrado**
> *Este documento constituye la especificación integral y formalizada de la plataforma NeuroLab Enterprise. Define de manera clara y didáctica la secuencia operativa paso a paso ('¿Qué es primero, qué sigue y qué viene después?'), el rol fundamental del Dataset como componente primario de análisis, el desglose detallado de los 10 módulos funcionales, los procedimientos técnicos de ejecución y las dos alternativas arquitectónicas de despliegue (Backend Python/PostgreSQL y Frontend Standalone en React/TensorFlow.js).*

1. Secuencia Operativa Paso a Paso (Guía para Demostración)

Para que el sistema NeuroLab Enterprise sea 100% funcional y operativo durante una presentación o evaluación técnica, es imprescindible seguir el orden cronológico estricto de ejecución. Cada paso prepara los insumos necesarios para el siguiente módulo:

PASO 1: M02 - Módulo de Proyectos (Creación del Workspace)

El usuario inicia sesión en la plataforma y crea un nuevo proyecto de Inteligencia Artificial especificando el problema a resolver. Este paso establece el contenedor global y asigna los permisos y roles de los integrantes.

PASO 2: M05 - Módulo de Datasets (Ingesta y Análisis Primario)

¡Componente Primario y Fundamental! El usuario sube el archivo de datos (CSV o estructurado). El sistema ejecuta un Análisis Exploratorio (EDA) automático, detecta la forma de entrada (input_shape = número de características) y la variable objetivo (target), y realiza la partición automática en Train (70%), Validation (15%) y Test (15%).

PASO 3: M04 - Diseñador de Arquitecturas (Construcción de la Red)

Con las dimensiones del dataset ya conocidas, el usuario abre el constructor gráfico. Selecciona la familia de red (Feedforward, CNN, RNN o GAN), configura la capa de entrada adaptada al dataset, añade las capas ocultas (unidades, activaciones ReLU/Tanh) y define la capa de salida (Sigmoid/Softmax). El sistema valida la compatibilidad dimensional.

PASO 4: M06 - Módulo de Entrenamientos (Ejecución del Aprendizaje)

El usuario vincula el Dataset (Paso 2) con la Arquitectura (Paso 3) y configura los hiperparámetros (épocas, batch size, optimizador Adam, learning rate). Al presionar 'Iniciar Entrenamiento', la tarea se envía al motor de cómputo (Worker Python/TensorFlow o ejecutor TensorFlow.js en cliente).

PASO 5: M07 - Evaluación y Métricas (Visualización en Tiempo Real)

Durante y al finalizar el entrenamiento, el sistema transmite las métricas época por época (Loss y Accuracy). Muestra gráficos interactivos de la curva de aprendizaje y evalúa el modelo final utilizando el subconjunto de datos de Prueba (Test) retenido en el Paso 2.

PASO 6: M08 / M09 - Registro de Modelos y Reportes (Versionado y Exportación)

Si los resultados son satisfactorios, el usuario aprueba el modelo, el cual se guarda de forma inmutable en el Model Registry (versión v1.0.0). Se habilita la descarga del archivo del modelo (.h5/.keras/.json) y la generación del reporte formal en PDF o CSV.

Tabla de Control de la Secuencia Operativa

Orden	Módulo Responsable	Acción Principal del Usuario	Entregable / Insumo Generado
1°	M02. Proyectos	Crear proyecto y definir el problema de IA.	ID de Proyecto y Workspace activo.
2°	M05. Datasets	Cargar dataset, realizar EDA y partición.	Metadatos, `input_shape` y splits (Train/Val/Test).
3°	M04. Arquitectura	Diseñar capas y funciones de activación.	Grafo y JSON de arquitectura validado.
4°	M06. Entrenamientos	Asignar hiperparámetros e iniciar ejecución.	Trabajo en marcha y ajuste de pesos en TensorFlow.
5°	M07. Métricas	Observar avance y evaluar rendimiento.	Gráficos de Loss/Accuracy y matriz de confusión.
6°	M08 / M09. Registro	Aprobar versión y exportar documentación.	Artefacto binario (.h5/.keras) y reporte PDF.

2. Justificación Técnica: El Dataset como Componente Primario

Existe la premisa fundamental en ciencia de datos: **"Los modelos de Deep Learning son tan buenos como los datos sobre los que se entrenan"**. El Dataset ocupa la posición inicial en la lógica de procesamiento por cuatro razones de arquitectura:

1. Condicionamiento Geométrico de la Red (Input & Output Shape)

La cantidad de variables independientes (columnas) del dataset establece de forma rígida la dimensión de entrada (input_shape) necesaria en la primera capa. Asimismo, la variable dependiente (target) condiciona la cantidad de neuronas de salida y la función de activación final (ej. Sigmoid para respuestas binarias 0/1, Softmax para clasificación multiclase).

2. Selección de la Familia de Arquitectura

El formato del dataset guía la elección tecnológica: si el dataset es una tabla estructurada (CSV/Excel) se selecciona una red Feedforward (MLP); si contiene imágenes se requiere una red Convolucional (CNN); si contiene datos secuenciales o temporales se emplea una red Recurrente (RNN/LSTM).

3. Preprocesamiento e Ingeniería de Características

Antes de configurar neuronas, el sistema analiza el dataset para limpiar valores nulos, codificar variables categóricas (One-Hot Encoding) y escalar numéricamente las funciones (Standardization / Min-Max Scaling), requisito indispensable para que los algoritmos de optimización por descenso de gradiente converjan.

4. Preservación del Subconjunto de Prueba (Test Set)

El dataset se divide al inicio en partes independientes. El subconjunto de prueba se retiene aislado durante todo el entrenamiento para garantizar una evaluación imparcial y evitar el sobreajuste (overfitting).

3. Especificación Detallada de Módulos Funcionales (M01 - M10)

M01. Inicio / Dashboard

Panel de control principal. Visualiza tarjetas de resumen con el total de proyectos, entrenamientos activos y recientes, estado de salud de la infraestructura y accesos directos al último workspace trabajado.

M02. Gestión de Proyectos de IA

Módulo de administración de proyectos. Permite la creación, edición, filtrado y búsqueda de proyectos de IA, asignación de descripción del problema, etiquetado y gestión de integrantes mediante permisos basados en roles (RBAC).

M03. Fundamentos Neurorales

Módulo académico/educativo interactivo. Ofrece Fichas conceptuales sobre la estructura de la red, demostraciones interactivas del funcionamiento de neuronas, pesos, sesgos y funciones de activación (ReLU, Sigmoid, Softmax, Tanh) junto a un glosario guiado.

M04. Diseñador de Arquitecturas

Constructor gráfico de redes neuronales. Incluye un selector de familias (Feedforward, RNN, CNN, GAN), editor de parámetros por capa (unidades, kernels, padding, activación), previsualización del grafo y validador automático de formas de entrada/salida.

M05. Datasets (Gestión de Datos)

Ingesta y administración de conjuntos de datos. Permite la carga controlada de archivos (CSV/imágenes), análisis exploratorio (EDA), validación de esquemas, división en subconjuntos (Train/Val/Test) y versionado de metadatos.

M06. Entrenamientos

Consola de ejecución de modelos. Configuración de hiperparámetros (épocas, batch size, optimizador, learning rate), control de ejecución (inicio, pausa, cancelación cooperativa) y seguimiento de la cola de prioridad.

M07. Evaluación y Métricas

Módulo de análisis de rendimiento. Generación de gráficos interactivos de Pérdida (Loss) y Precisión (Accuracy) por época, evaluación contra el dataset de prueba, matrices de confusión y comparación entre distintos experimentos.

M08. Registro de Modelos (Model Registry)

Catálogo centralizado de artefactos de modelos entrenados. Garantiza el versionado inmutable (v1.0, v1.1), gestión de estados (Borrador, En Revisión, Aprobado, Retirado) y descarga de archivos binarios (.h5, .keras, .json).

M09. Reportes y Documentación

Motor de exportación de resultados. Generación automática de fichas de proyecto, resúmenes arquitectónicos, gráficos de rendimiento e historial de entrenamiento en formatos descargables PDF y CSV.

M10. Administración y Seguridad

Consola de gobierno de la plataforma. Administración de usuarios, roles y permisos, auditoría completa de eventos (Audit Logs), control de cuotas y límites de recursos (CPU/GPU) y configuraciones del sistema.

4. Modelos de Despliegue y Arquitectura Técnica

El sistema NeuroLab Enterprise está diseñado para ser flexible y adaptarse a dos modos de operación según los requerimientos de la infraestructura:

Modalidad A: Arquitectura Empresarial Backend (Python + PostgreSQL)

Orientada a entornos de producción enterprise donde se requiere almacenamiento centralizado, multiusuario colaborativo y procesamiento distribuido:

- **Frontend:** React + TypeScript + Vite para la experiencia de usuario y visualización de gráficos.
- **API REST:** FastAPI (Python) para la validación de contratos, autorización y gestión de proyectos.
- **Cómputo ML:** Workers desacoplados ejecutan TensorFlow/Keras en segundo plano consumiendo una cola de trabajos (Redis/Celery).
- **Persistencia:** PostgreSQL para metadatos, historial de auditoría y métricas por época.

Modalidad B: Arquitectura Autónoma Client-Side (100% Frontend / Standalone)

Orientada a demostraciones locales, ejecución sin servidor o entornos académicos simplificados sin base de datos:

- **Interfaz & Estado:** React + TypeScript gestionado con Zustand y almacenamiento persistente en LocalStorage.
- **Motor ML Local:** @tensorflow/tfjs ejecuta el entrenamiento directo en la memoria GPU/WebGL del navegador del usuario.
- **Datasets y Pesos:** IndexedDB almacena localmente los archivos CSV subidos y los pesos binarios de los modelos (.bin).
- **Exportación PDF:** jsPDF genera reportes y documentación técnica del proyecto directamente en el cliente.